ADN del Entrenador

Cómo separar el estilo de un DT del de su plantilla

Sebastian Dulong Salazar

Coach DNA · ISAC Hackathon 2026 · Octubre de 2026

Resumen. Cuando un equipo presiona alto, ¿es por el entrenador o por los jugadores que tiene? Los dos aparecen juntos en cada partido, así que cualquier perfil del equipo los mezcla. Este trabajo propone, hasta donde sabemos, la primera descomposición del *estilo de juego* que separa al DT de su plantilla, y lo hace con tres ideas que no se habían combinado en el futbol. (**1**) Llevamos al estilo el método de efectos fijos de dos vías de la economía laboral (Abowd, Kramarz y Margolis), que en futbol sólo se había usado para medir *resultados* de entrenadores. (**2**) Le sumamos a los jugadores que están en la cancha en cada tramo, como el *plus-minus* regularizado del básquetbol, para separar en 34 rasgos al DT, la plantilla, el club, el rival y el contexto. (**3**) Lo estimamos con estadística bayesiana en dos capas: un *prior* por pieza que no le inventa estilo a un DT con pocos datos, y una *huella latente* empírico-bayesiana que comparte información entre rasgos con dos factores de estilo, y que mejora la separación justo en los DTs más difíciles de separar. Con 1,807 partidos de Liga MX (2021/22 a 2026/27) y 103 DTs, la plantilla explica casi la mitad de las diferencias de estilo entre equipos y el DT alrededor del 14 %; el DT decide sobre todo *cómo* se juega y los jugadores *cuánto* peligro se genera. Validamos el método fuera de muestra: si escondemos un club entero, el modelo reconoce al DT real en la mitad de arriba de 70 candidatos en 50 de 63 casos, y en datos simulados recupera un estilo sembrado mucho mejor que un perfil de equipo. Todo se convierte en decisiones (plan contra un rival, fichajes a la medida y seguimiento) en una app interactiva para los 76 DTs con perfil.

1. El problema

Lo que vemos en un partido mezcla cinco cosas: las ideas del **DT**, la calidad de su **plantilla**, lo propio del **club**, el **rival** de ese día y el **contexto** (marcador, minuto, localía). Decir "el Pachuca de Almada presiona alto" no aclara si eso lo pone Almada o lo ponen sus jugadores, porque cada partido del DT es también un partido de su plantel. Promediar sus partidos no los separa.

Nuestra pregunta es otra: ¿qué variación de los datos nos deja ver al DT sin sus jugadores? La Figura 1 resume el camino.

Qué es nuevo. Hasta donde sabemos, ningún trabajo público combina estas piezas para el estilo de un DT:

- **Estilo, no resultados.** El método de economía laboral que separa a un trabajador de su empresa se había aplicado a los *resultados* de entrenadores en la Bundesliga; aquí separa cada uno de 34 rasgos de estilo.
- **Cinco piezas a la vez.** DT, jugadores en cancha (a la manera del *plus-minus* del básquetbol), club, rival y contexto, con tramos de partido sin cambios ni goles como unidad.
- **Bayesiano en dos capas.** Un *prior* por pieza (no inventa estilos con pocos datos) y una huella latente empírico-bayesiana que aprende de todos los rasgos a la vez.
- **Pruebas fuera de muestra.** Esconder clubes enteros, sembrar estilos conocidos en datos simulados y seguir a los DTs que cambian de club.
- **Del número a la decisión.** Plan contra un rival, fichajes, seguimiento semanal y simulación para explicar resultados, en una app abierta.

2. Datos

Usamos los eventos de StatsBomb (con xG y OBV) y las fotos 360 de 1,807 partidos de Liga MX en seis temporadas (hasta el 19 de octubre de 2026): 103 DTs y 980 jugadores con minutos suficientes.

La unidad son tramos cortos. Partimos cada partido en tramos de al menos 5 minutos en los que no cambian ni los 22 jugadores ni el marcador (24,548 tramos). Así sabemos exactamente quién estaba en cancha y cómo iba el partido en cada momento.

El estilo son 34 indicadores en ocho familias: construcción, progresión, ocasiones, presión, organización defensiva, transiciones, dominio y balón parado. Por ejemplo, la *salida corta del portero* es la parte de sus pases que miden menos de 35 yardas: la liga promedia 51 % y los equipos de Almada, 39 %. Para poder comparar indicadores distintos, cada uno se mide en *desviaciones típicas* (σ) entre equipos: $+1\sigma$ es tanto como se diferencia un equipo típico de otro.

3. El método

La idea

Para cada indicador, el estilo de un tramo se explica como una suma de piezas:

$$z = \underbrace{\alpha_{\text{DT}}}_{\text{entrenador}} + \underbrace{\phi_{\text{club}}}_{\text{club}} + \underbrace{\sum_j \beta_j}_{\text{jugadores en cancha}} + \underbrace{\gamma_{\text{rival}}}_{\text{rival}} + \underbrace{\delta\, x}_{\text{contexto}} + \underbrace{\varepsilon}_{\text{ruido}} \tag{1}$$

Lo que buscamos es α_{DT}: cómo jugaría ese entrenador con una plantilla, un club y unos rivales promedio. Es el modelo AKM (Abowd et al., 1999), que Muehlheusser et al. (2018) usaron con DTs de la Bundesliga para explicar *resultados*. Nosotros lo aplicamos al *estilo* y le sumamos a los jugadores en cancha, como en el *plus-minus ajustado* del básquetbol y el hockey (Macdonald, 2012).

¿De dónde sale la separación?

Si un DT dirigiera un solo club con jugadores que nunca jugaron para nadie más, sería imposible separarlo de ellos. Tres cosas lo hacen posible:

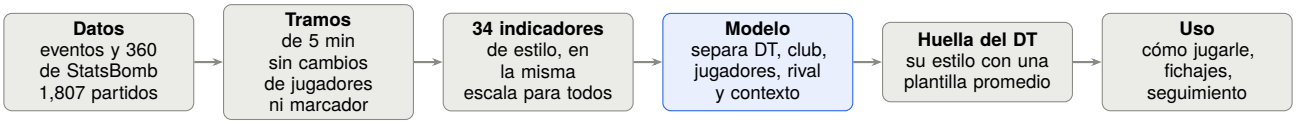


Figura 1. Del dato al uso. El paso clave (azul) es el modelo que separa al DT del resto.

- **DTs que cambian de club.** Si Almada mantiene un rasgo en Santos, Pachuca y América, con tres plantillas distintas, ese rasgo no puede venir solo de sus jugadores.
- **Jugadores con varios DTs.** Si los porteros del Pachuca salían corto con otro entrenador, hay contra qué comparar.
- **Cambios dentro del partido.** Con cada sustitución cambia quién está en cancha y el DT no.

Cómo se estima

Con una regresión *ridge*: busca las piezas que mejor explican los datos, pero castiga los valores grandes,

$$\text{mín} \sum_{\text{tramos}} w\,(z - \text{piezas})^2 \;+\; \lambda \cdot \|\text{piezas}\|^2. \qquad (2)$$

Esta penalización es estadística bayesiana: equivale a suponer, antes de ver los datos, que cada pieza vale cero (el promedio de la liga) con una incertidumbre propia, y quedarse con la estimación más probable una vez vistos los partidos. Cada pieza tiene su propio λ (su "prior"): al DT se le pide más evidencia que al contexto, y a un jugador más que al DT. El efecto práctico es que, cuando los datos no alcanzan para separar al DT de su plantilla, el modelo lo deja cerca del promedio de la liga en vez de inventarle un estilo. Es una postura conservadora: al DT solo se le atribuye lo que los datos respaldan. Además, cada DT lleva un *índice de identificabilidad* de 0 a 100 según cuántos clubes dirigió y cuántos de sus jugadores jugaron con otros DTs (Almada: 96). Como último paso, la huella pasa por un modelo de aprendizaje multitarea que comparte información entre rasgos (Sección 5).

Cuánto pesa cada pieza

Con el modelo estimado podemos medir qué parte de las diferencias de estilo entre equipos explica cada pieza m:

$$\text{peso}_m = \frac{\text{Cov}(m,\, z)}{\text{Var}(z)}, \qquad \textstyle\sum_m \text{peso}_m = 1. \qquad (3)$$

La Figura 2 pone el tono: la plantilla pesa más que el entrenador. Pero el 14 % del DT es real y cambia mucho según el indicador (Figura 3): llega al 27 % en acciones progresivas, al 20 % en recuperaciones en campo rival y al 19 % en ritmo de pase, y baja a 4 o 7 % en xG y OBV.

El DT decide cómo se juega; cuánto peligro sale de eso depende más de los jugadores.

4. ¿Funciona?

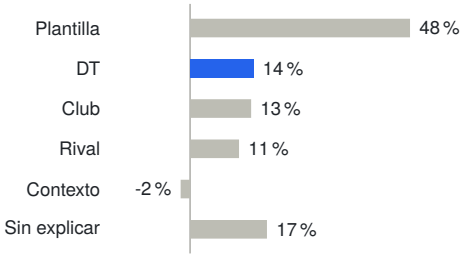


Figura 2. La plantilla explica casi la mitad del estilo; el DT, 14 %. Promedio de los 34 indicadores, a nivel equipo y temporada. Las partes suman 100 %; el contexto resta un poco porque va en contra de las diferencias entre equipos (los que dominan el balón suelen ir ganando, y ganando lo sueltan).

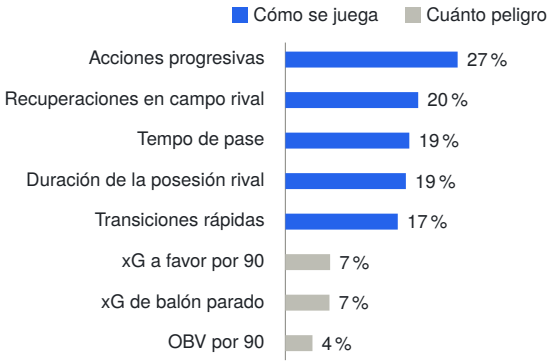


Figura 3. Parte del estilo que explica el DT, por indicador.

Prueba 1: un estilo que sabemos que existe

Sobre los mismos partidos, DTs y jugadores reales, "plantamos" un estilo de DT conocido, le sumamos ruido real y le pedimos al modelo que lo encuentre (30 repeticiones). Lo probamos en un escenario realista y en el peor caso posible: cada DT con jugadores parecidos a él, que es justo la confusión que queremos deshacer.

El modelo se acerca más a la verdad en los dos casos (Figura 4). Y cuando plantamos que el DT *no* importa, el promedio simple igual "ve" grandes diferencias entre DTs (0.96σ); el modelo casi no ve nada (0.19σ). Cuando marca un rasgo como claro, acierta su dirección 82 % de las veces; su tamaño, en cambio, lo da más chico de lo real.

Prueba 2: esconder un club entero

Para cada DT que dirigió dos o más clubes (63 etapas), escondemos todos sus partidos en un club, volvemos a estimar sin ellos y preguntamos: de 70 DTs posibles, ¿a quién se parece más ese equipo? Si el DT verdadero sale arriba con una plantilla que el modelo nunca vio con él, su estilo viajó con él. Al azar, quedaría entre los 10 primeros solo el 14 % de las veces.

El DT verdadero queda en la mitad de arriba en 50 de las 63 etapas (Figura 5). La mejora del modelo sobre

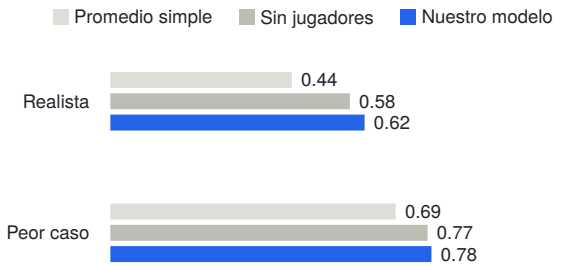


Figura 4. El modelo encuentra el estilo plantado mejor que el promedio de partidos. Correlación entre el estilo plantado y el que recupera cada método.

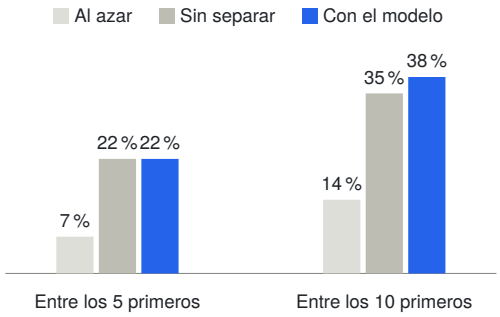


Figura 5. Con un club escondido, el DT verdadero queda entre los 10 más parecidos de 70 en el 38 % de los casos. Porcentaje de las 63 etapas.

el perfil sin separar es pequeña pero va en la dirección esperada.

Prueba 3: cuando un DT llega a un club nuevo

En 40 llegadas de un DT a un club nuevo, el estilo del equipo se mueve hacia el que ese DT traía de antes, más de lo que se movería por azar ($p = 0.008$). Y si a la vez quitamos piezas del modelo, predecir partidos nuevos empeora más al quitar a los jugadores que al quitar al DT, lo mismo que dice la Figura 2.

5. Una vuelta de ML: la huella latente

El ridge estima cada uno de los 34 rasgos por separado. Eso tiene un punto débil: cuando un rasgo de un DT está mal separado de su plantilla, su estimación es ruidosa y no hay nada más que la rescate. Pero los rasgos de estilo no son independientes: quien presiona alto también recupera arriba y deja menos tiempo de posesión al rival. Lo que un DT muestra en los rasgos que *sí* están bien identificados dice algo de los que no.

La idea. Suponemos que la huella de cada DT vive cerca de un espacio de pocos "factores de estilo" y la aprendemos con un modelo jerárquico (un análisis factorial con encogimiento empírico-bayesiano, emparentado con la factorización de matrices de los sistemas de recomendación):

$$\hat{\alpha}_c^{\text{latente}} = \Sigma\,(\Sigma + S_c)^{-1}\,\hat{\alpha}_c, \qquad \Sigma = \Lambda\Lambda^{\top} + \Psi. \quad (4)$$

Σ dice cómo se mueven juntos los rasgos entre DTs y se aprende con todos ellos (EM). Λ son los factores de estilo, y S_c es el ruido de cada rasgo para ese DT, medido comparando dos mitades de sus partidos. La fórmula hace sola lo que queremos para la separabilidad: si un rasgo tiene mucho ruido para un DT (está pegado a su plantilla), pesa poco, y su valor se reconstruye con los rasgos correlacionados en los que ese mismo DT sí está claro. Si tiene poco ruido, casi no se toca.

¿Ayuda? Antes de usarla en la app la probamos: aprendemos todo con una mitad de los partidos y medimos qué tan bien predice la huella de la otra mitad (Figura 8).

Mejora en las cuatro particiones, de 0.570 a 0.585, y lo mismo entre los DTs más difíciles de separar (de 0.541 a 0.550). El encogimiento rasgo por rasgo, sin compartir información, se queda en 0.572: la ganancia viene de compartir entre rasgos. Es una mejora modesta, pero cae donde debe. Los rasgos que más ganan son los más ruidosos y los más pegados a la calidad de la plantilla: llegadas al área y xG de balón parado (+0.04 cada uno), entradas al último tercio y tiros.

Dos factores con sentido futbolístico. El mejor modelo usa dos factores, que explican el 52 % de cómo se mueven juntos los rasgos. El primero es *dónde defiende*: altura de la presión, de la línea y de las recuperaciones frente a la duración de la posesión rival. El segundo es *cómo ataca*: vertical y con acciones progresivas, o elaborado, con más pases por posesión. Son los mismos dos ejes del mapa de estilos de la app, encontrados aquí sin decírselos al modelo.

6. Ejemplo: Guillermo Almada

Almada es un caso ideal: 170 partidos en tres clubes, y el 89 % de los minutos de sus jugadores es de futbolistas que también jugaron con otros DTs.

De dónde sale un número. Sus porteros sacan corto el 39 % de las veces y la liga, el 51 %: una diferencia de 1.37σ. Un perfil "del equipo" se la cargaría toda a Almada. El modelo la reparte entre las piezas (Figura 6) y le atribuye a él poco más de un tercio; el resto viene del club, de sus porteros y defensas y del contexto.

Su huella. Ya descontada la plantilla, sus rasgos más claros (Figura 7) dibujan un estilo reconocible: *roba arriba, avanza conduciendo, cambia de orientación y no deja que el rival tenga el balón mucho tiempo*. Su portero, además, juega largo.

¿Viaja con él? Escondimos sus 11 partidos en América. Sin separar, ese América se parece a Almada en el puesto 5 de 70; con el modelo, en el **puesto 1**. También es estable en el tiempo: cada torneo suyo se parece al resto de su carrera más que en el 92 % de los DTs.

7. Para qué sirve

Todo sale del mismo modelo, así que los números de la app y los de este texto coinciden.

- **Cómo jugarle.** Cada rasgo claro del DT se traduce en una recomendación para el rival. Contra Almada: ganar el primer balón y la segunda jugada (su portero saca largo), superar su presión con juego directo y cortar a sus conductores.
- **Cara a cara.** Cruza dos estilos y dice qué duelo puede decidir el partido, y cómo cambia cada DT según

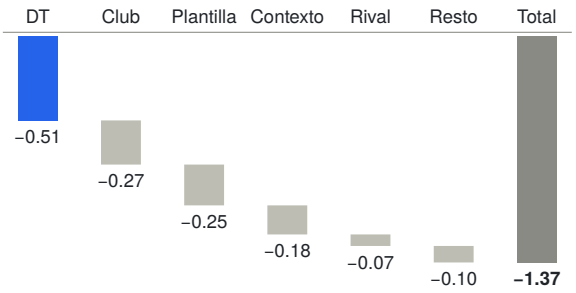


Figura 6. Salida corta del portero de Almada frente a la liga, repartida entre las piezas del modelo (en σ; "resto" es lo que el modelo no explica). El 37 % de la diferencia es suya.

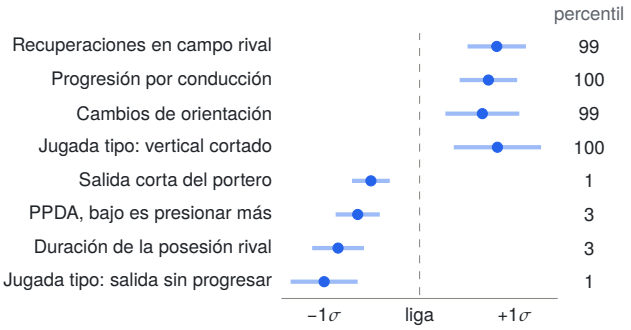


Figura 7. Su huella: el efecto propio de Almada en sus ocho rasgos más claros, ya descontada la plantilla, con su margen de error y su percentil entre los DTs.

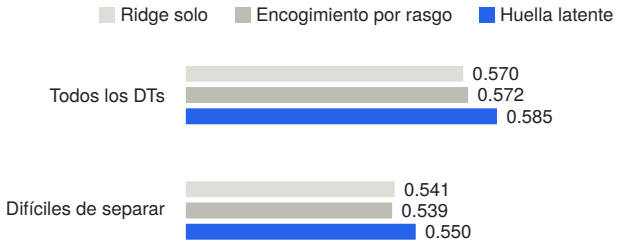


Figura 8. La huella latente predice mejor la otra mitad de los partidos. Correlación media entre la huella de una mitad y la de la otra (4 particiones, unos 50 DTs; "difíciles de separar": identificabilidad menor a 80). El eje empieza en 0.45 para que se vean las diferencias.

el minuto y el marcador. Entre el 60′ y el 75′, los equipos de Almada contragolpean bastante más que la liga.

- **Jugadores a su medida.** Como el modelo también mide a cada jugador sin su DT, podemos buscar a quienes empujan los rasgos de un entrenador. Para Almada: Pavel Pérez (Toluca), César Huerta y Alan Medina (Pumas).
- **Seguimiento.** Compara sus últimos 10 partidos con lo esperable en su carrera: ¿sigue jugando igual?
- **Balón parado.** Córners, tiros libres y saques de banda por club. Con la foto 360 medimos si marca al hombre o en zona: Almada es de los más al hombre de la liga.

8. Límites

- El modelo es conservador: acierta la dirección de los rasgos claros, pero tiende a darlos más chicos de lo que son. La huella latente mejora poco (1.5 puntos de correlación); la app ya la usa, pero su margen de error sigue siendo el del ridge, que es más ancho.
- Un DT de un solo club, con jugadores que no jugaron con nadie más, queda cerca del promedio. Por eso cada DT lleva su índice de identificabilidad.
- No capta que un DT saque lo mejor de un jugador en particular, y no hay datos de seguimiento continuo: el 360 es una foto del momento de cada jugada.
- Los datos de StatsBomb son de uso exclusivo para la competencia; solo publicamos resultados agregados.

Referencias

Abowd, Kramarz y Margolis (1999). High wage workers and high wage firms. *Econometrica* 67(2).

Fernández-Navarro et al. (2016). Attacking and defensive styles of play in soccer. *J. Sports Sciences* 34(24).

Macdonald (2012). Adjusted plus-minus for NHL players using ridge regression. *J. Quant. Analysis in Sports* 8(3).

Muehlheusser, Schneemann, Sliwka y Wallmeier (2018). The contribution of managers to organizational success: Evidence from German soccer. *J. Sports Economics* 19(6).